Statistiques descriptives & Visualisation de données

Statistiques univariées & bivariées – Solutions

§1. Étude de cas : Qualité de l'air en Auvergne-Rhône-Alpes

Chaque année, nous estimons qu'en France plusieurs dizaines de milliers de décès sont dûs à une mauvaise qualité de l'air, et plusieurs millions dans le monde. C'est pourquoi de nombreuses villes étudient et publient un **indice de qualité de l'air** ayant pour but : l'évaluation de la qualité de l'air, l'aide à la décision, et la communication au public.
En France, pour les agglomérations de plus de 100 000 habitants, l'indice retenu est l'indice ATMO. Il vise à étudier la qualité de l'air en mesurant les concentrations de dioxyde de souffre, dioxyde d'azote, d'ozone, et de particules en suspension (PM_{10} seulement) à l'échelle d'une agglomération ou d'une région.
Nous nous proposons une étude préliminaire de la concentration des particules fines en suspension dans l'air PM_{10} (d'un diamètre inférieur à 10 micromètres) dans la région Auvergne-Rhône-Alpes. Pour ce faire, nous avons téléchargé les données issues de ATMO France [1] : **Indice_ATMO_ARA.csv**. Dans ce fichier, nous retrouvons les relevés de concentration correspondantes à la journée du 13 novembre 2023.

1. Écrire les fonctions Python prenant une liste de nombres en entrée et retournant les principaux paramètres de cette liste : moyenne, médiane, variance, écart-type, premier et troisième quantile.
2. Importer le fichier **Indice_ATMO_ARA.csv**, et récupérer la
3. Déterminer les moyenne, médiane, variance, écart-type, premier et troisième quantile de la série des mesures de concentration de PM_{10}.
4. Représenter graphiquement cette série. Commenter.
5. (a) Selon la législation française, le seuil moyen annuel de concentration de particules PM_{10} à ne pas dépasser est fixé à $40\ \mu g.m^{-3}$. Ce seuil a-t-il été dépassé entre le 7 novembre 2023 et le 13 novembre 2023 pour la région Auvergne-Rhône-Alpes ?
   (b) Le seuil de $20\ \mu g.m^{-3}$ a-t-il été dépassé cette même semaine pour la région Auvergne-Rhône-Alpes ?
6. Nous définissons ici la *région lyonnaise* comme étant l'ensemble des villes de Lyon, Villeurbanne, Feyzin et Vénissieux, et la *région grenobloise* comme l'ensemble des villes de Grenoble, Gières, Meylan, Eybens et Fontaine.
   (a) Récupérer dans deux DataFrame les concentrations de particules PM_{10} des régions lyonnaise et grenobloise.
   (b) En visualisant les boîtes à moustaches, comparer les concentrations de particules PM_{10} pour ces deux régions.
7. Écrire une fonction Python qui prend deux listes en entrée et retourne le coefficient de corrélation entre ces deux listes.
8. Simuler une droite de régression linéaire.
9. Calculer le coefficient de corrélation entre la concentration des particules PM_{10} et la concentration d'ozone O_3 dans la région lyonnaise. Commenter.
10. Déterminer la droite de régression linéaire entre ces deux séries. Commenter.

1. Il s'agit d'une association fédérant le réseau national des associations de surveillance de la qualité de l'air, et composée de de 18 organismes régionaux agréés par le ministère chargé de l'environnement.

§2. Quelques exercices

Exercice 1 – Le tableau suivant représente la répartition des étudiants français ayant bénéficié du programme Erasmus de 2002/2003 à 2007/2008 par rapport au pays d'accueil.

Pays / Année	2002/2003	2003/2004	2004/2005	2005/2006	2006/2007	2007/2008
Espagne	4470	5115	5167	5481	5454	5281
Royaume-Uni	4705	4652	4564	4499	4673	4299
Allemagne	2808	2804	2863	2884	2800	2618
Italie	1415	1549	1571	1642	1638	1654

1. Quelle est la population étudiée ?
2. Quels sont les individus ?
3. Quels sont les caractères ?
4. Quelle est la nature des caractères ?

Solution.
1. La population étudiée est l'ensemble des étudiants français ayant bénéficié du programme Erasmus.
   *Rappel : La **population statistique** est l'ensemble des **individus** sur lesquels porte l'étude statistique.*
2. Un individu est un étudiant français ayant bénéficié du programme Erasmus
   *Rappel : Un **individu** (ou une **unité statistique** est chaque élément étudié.*
3. Les caractères sont : le pays d'accueil ; ainsi que l'année d'échange du programme Erasmus.
   *Rappel : Le **caractère** est la propriété étudiée chez ces individus.*
4. La nature du pays d'accueil est qualitative (Espagne, Royaume-Uni, Allemagne et Italie) ; et la nature de l'année d'échange est qualitative (2002/2003, 2003/2004, 2004/2005, 2005/2006, et 2006/2007).
   *Rappel : On distingue les caractères selon leur **nature** : **qualitative**, c'est-à-dire nommé par une qualité, un nom propre, etc., ou **qantitative**, c'est-à-dire mesurable à l'aide d'un nombre.*

Exercice 2 – On considère la répartition des ménages de moins de 6 personnes en France métropolitaine selon le nombre de personnes en 2008 (d'après le recensement de la population réalisé par l'INSEE).

Nombre de personnes	1	2	3	4	5	6
Nombre de ménages	8914849	8776420	3911419	3303676	1240991	468123

1. Représenter graphiquement cette série.
2. Calculer la moyenne arithmétique de cette série.
3. Calculer la médiane, q_1 et q_3.
4. Calculer l'écart-type.

Solution. Définissons tout d'abord nos séries (afin d'effectuer les calculs en Python).

```
# Séries
personnes = [1, 2, 3, 4, 5, 6]
effectif = [8914849, 8776420, 3911419, 3303676, 1240991, 468123]
```

1. Nous représentons l'histogramme du nombre de personnes dans un ménage.

```
# Histogramme
np.histogram(personnes, bins = personnes, weights = effectif)
plt.hist(personnes, bins = personnes, edgecolor = 'grey', color = 'lightblue',
```

```
            weights = effectif)

# Histogramme des fréquences
plt.hist(personnes, bins = personnes, edgecolor = 'grey', color = 'lightblue',
            weights = effectif, density = TRUE)
```

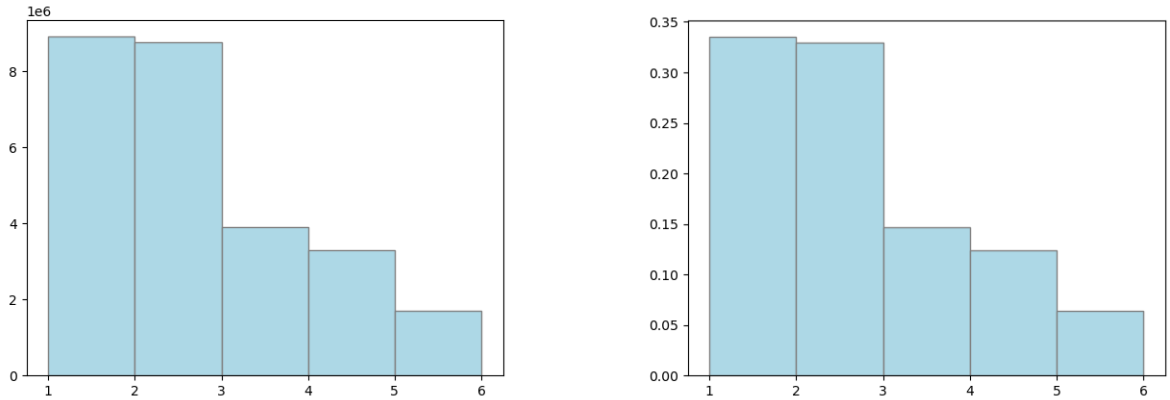

Figure 1 – Histogrammes du nombre (resp. de la fréquence du nombre) de personnes dans un ménage en France à gauche (resp. à droite).

2. L'effectif totale de la série est

$$n = \sum_{i=1}^{6} n_i = 8\,914\,849 + 8\,776\,420 + 3\,911\,419 + 3\,303\,676 + 1\,240\,991 + 468\,123 = 26\,615\,478,$$

où n_i est le nombre de ménages à i personnes.
La moyenne de cette série est alors

$$\begin{aligned}\bar{x}_n &= \frac{1}{n}\sum_{i=1}^{6} i \times n_i \\ &= \frac{1 \times 8\,914\,849 + 2 \times 8\,776\,420 + 3 \times 3\,911\,419 + 4 \times 3\,303\,676 + 5 \times 1\,240\,991 + 6 \times 468\,123}{26\,615\,478} \\ &= 2.270.\end{aligned}$$

3. Puisque l'effectif total de la série est pair, la médiane est donc donnée par la moyenne des valeurs situées en positions $\frac{n}{2} - 1 = 13\,307\,738$ et $\frac{n}{2} = 13\,307\,739$ de la série. Dans notre cas, le nombre de personnes dans les ménages correspondants sont 2 et 2 ; ainsi la médiane est alors égale à :

$$m_e = \frac{2+2}{2} = 2.$$

De la même manière on détermine les premier et troisième quartiles. L'effectif total n'est pas divisible par, donc les premier et troisième quartiles, notés respectivement q_1 et q_3 sont égaux aux valeurs situées en position $\lceil \frac{n}{4} \rceil = 6\,653\,870$ et $\lceil \frac{3n}{4} \rceil = 19\,961\,609$ respectivement de la série. Ici on obtient donc :

$$q_1 = 1 \quad \text{et} \quad q_3 = 3.$$

4. La variance est égale à

$$s_n^2 = \frac{1}{n}\sum_{i=1}^{n} (x_i - \bar{x}_n)^2.$$

En d'autres termes, il s'agit de *la moyenne des carrés des écarts à la moyenne*.
Pour notre série, elle peut également s'écrire

$$s_n^2 = \frac{1}{n}\sum_{j=1}^{k} n_j e_j^2 - \bar{x}_n^2,$$

où $e_j = 1, \ldots, 6$, et n_j est le nombre de ménages dans lesquels il y a j personnes. La moyenne de la série vaut $\bar{x}_n =$, et la variance est donc égale à

$$\begin{aligned} s_n^2 &= \frac{1}{n}\sum_{j=1}^{6} n_j \times j^2 - \bar{x}_n^2 \\ &= \frac{1}{26\,615\,478}\Big(8\,914\,849 \times 1^2 + 8\,776\,420 \times 2^2 + 3\,911\,419 \times 3^2 + 3\,303\,676 \times 4^2 \\ &\qquad\qquad + 1\,240\,991 \times 5^2 + 468\,123 \times 6^2\Big) - (2.270496)^2 \\ &= 1.606. \end{aligned}$$

Et l'écart-type est alors :

$$s_n = \sqrt{s_n^2} = 1.267.$$

Exercice 3 – Un agriculteur trouve que ses plants de tomates "tiny Tim" semblent plus petits que d'habitude. Il mesure alors la hauteur de ses plants de tomates (en pouces) et observe les valeurs suivantes :

$$12, \quad 8.4, \quad 10, \quad 9.8, \quad 14, \quad 7.9, \quad 11, \quad 12.7, \quad 13.7.$$

1. Visualiser les données.
2. L'année précédente, il avait calculé les quantités suivantes : $\min = 9$, $q_1 = 11$, $q_2 = 13.4$, $q_3 = 16$ et $\max = 17$. Dessiner la boîte à moustaches correspondante. Pensez-vous que la crainte de l'agriculteur soit justifiée ?

Solution. 1. Au vu de la question suivante, le plus intéressant semble la visualisation de l'histogramme et de la boîte à moustache.

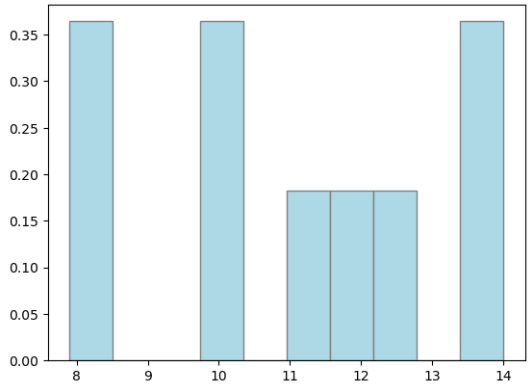

Figure 2

2.

Exercice 4 – Le tableau suivant correspond aux dépenses militaires (représenter en % du PIB) pour différents pays.

Arabie Saoudite	10.82	Italie	1.44
Russie	4.55	Norvège	1.36
États-Unis	3.50	Finlande	1.34
Inde	2.43	Allemagne	1.20
Grèce	2.26	Pays-Bas	1.15
France	2.20	Japon	1.00
Turquie	2.20	Espagne	0.92
Serbie	2.17	Suisse	0.75
Chine	2.09	Autriche	0.75
Royaume-Uni	2.02	Irlande	0.47
Portugal	1.83	Luxembourg	0.46

1. Tracer l'histogramme de ces données avec les classes $[0, 0.5[, [0.5, 1.5[, [1.5, 3[, [3, 5[, [5, 12[$.
2. Dessiner la boîte à moustaches pour ces données en précisant avec soin les points d'intérêt.

Solution. 1.

2.

Exercice 5 – On répertorie le temps nécessaire à douze étudiants à peine diplômés pour trouver un emploi. Les valeurs obtenues (en mois) sont $0, 1, 1, 2, 2, 2, 3, 3, 4, 5, 7, 10$.

1. Calculer la moyenne arithmétique de ces données.
2. Calculer la médiane et la valeur modale.
3. Calculer les premier et troisième quartiles et en déduire l'IQR.
4. Calculer la variance, l'écart-type et un indicateur de dissymétrie.
5. Visualiser les données.
6. Visualiser les données avec 3 histogrammes dont les classes sont respectivement :
   (a) $[0, 2],]2, 4],]4, 6],]6, 8],]8, 10]$;
   (b) $[0, 2],]2, 6],]6, 10]$;
   (c) $[0, 1],]1, 2],]2, 4],]4, 10]$.
7. Considérons la grandeur $Y = 3X - 2$. Calculer la moyenne et la variance de la série $\{y_1, \dots, y_{12}\}$ définie pour tout $i = 1, \dots, 12$ par $y_i = 3x_i - 2$.
8. Même question en considérant la grandeur $Z = 3X^2$.

Solution. 1. La moyenne arithmétique de cette série est

$$\bar{x}_n = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{0+1+1+2+2+2+3+3+4+5+7+10}{12} = \frac{10}{3}.$$

2. Cette série est constituée de 12 valeurs, ainsi la médiane est la moyenne des 5e et 6e valeurs de la série, c'est-à-dire
$$m_e = \frac{2+2}{2} = 2.$$
Puis le *mode* est la valeur la plus représentée dans la série. Ici le mode est égal à 2.
3. Comme précédemment, puisque 12 (la longueur de la série) est divisible par 4, les premier et troisième quartiles, notés respectivement par q_1 et q_3, sont alors donnés par les moyennes des 2ème et 3ème valeurs ; et des 8ème et 9ème valeurs, c'est-à-dire :
$$q_1 = \frac{1+1}{2} = 1 \quad \text{et} \quad q_3 = \frac{3+4}{2} = 3.5.$$

4. Déterminons maintenant la variance et l'écart-type de la série. La variance est égale à :

$$\begin{aligned} s_n^2 &= \frac{1}{n}\sum_{i=1}^{n}\left(x_i - \bar{x}_n\right)^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}_n^2 \\ &= \frac{0^2+1^2+1^2+2^2+2^2+2^2+3^2+3^2+4^2+5^2+7^2+10^2}{12} - \frac{100}{9} \\ &= \frac{233}{18} \simeq 7.389. \end{aligned}$$

L'écart-type est alors

$$s_n = \sqrt{s_n^2} = \frac{1}{3}\sqrt{\frac{233}{2}} \simeq 2.718.$$

Le coefficient d'asymétrie est définie par :

$$\gamma = \frac{1}{n}\sum_{i=1}^{n}\frac{\left(x_i - \bar{x}_n\right)^3}{s_n^3}.$$

Ici ce coefficient est $\gamma \simeq 1.16$. Le coefficient γ est strictement positif, donc la queue de distribution de la série est étalée vers la droite.

5. On peut visualiser les données de plusieurs manières donnant des informations différentes pour chacune d'entre elles.

   - *Diagramme en « bâtons »*. Il permet de visualiser les données lorsque ces dernières ne sont pas regroupées en classes.

```
# Diagramme en bâtons
plt.bar(range(12), serie, width=0.5,
        color='yellow',
        edgecolor='blue',
        linewidth = 1)
plt.xticks(range(12), ['A','B','C',
        'D','E','F','G','H','I',
        'J','K','L'], rotation=45)
```

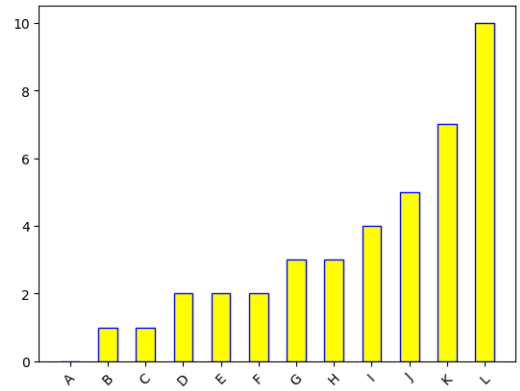

   - *Polygones des effectifs (cumulés)*. À partir du diagramme en bâton des effectifs (resp. des fréquences), le polygone des est obtenu en joignant pas un segment les sommets des bâtons.

```
# Polygone des effectifs cumulés
plt.plot(range(12), serie, marker='o', color='red', markersize=5)
```

   - *Histogrammes.* Lorsque les données sont regroupées par classes, nous pouvons représenter la série statistique en dessinant au dessus de chaque classe un segment horizontal tel que les aires des rectangles ainsi formés soient proportionnelles aux effectifs (ou aux fréquences) de la classe.
     De même que pour les diagrammes en bâtons, il est possible d'obtenir les polygone des effectifs ou des fréquences d'une distribution statistique en joignant les milieux des côtés horizontaux supérieurs.)
     Lorsque les classes ont toutes la *même taille*, les histogrammes des fréquences et des fréquences cumulées permettent d'obtenir des informations sur la distribution des données (par exemple distribution normale, distribution exponentielle, loi gamma, loi du χ^2, etc...)

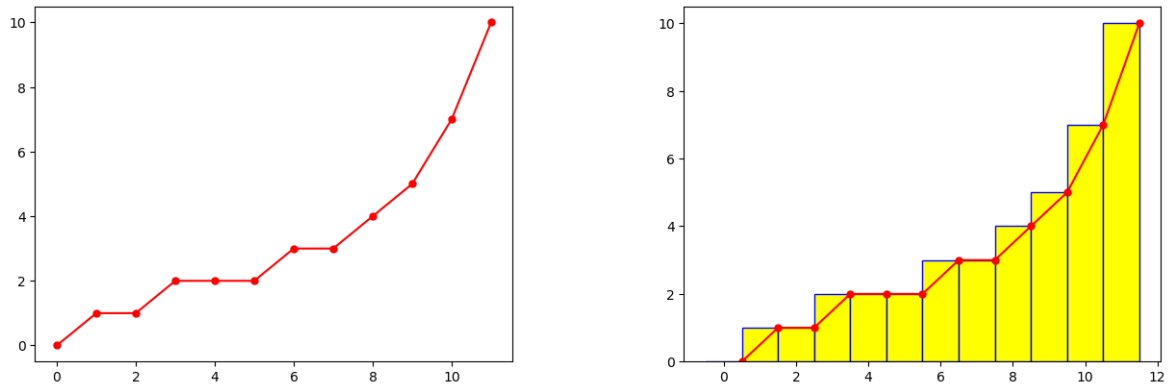

Figure 3 – Polygone des effectifs à gauche (resp. obtenu à partir du diagramme en bâtons des effectifs cumulés à droite).

```
# Histogramme des effectifs
np.histogram(serie) plt.hist(serie, edgecolor = 'grey', color = 'lightblue')

# Histogrammes des fréquence
plt.hist(serie, density = True)
```

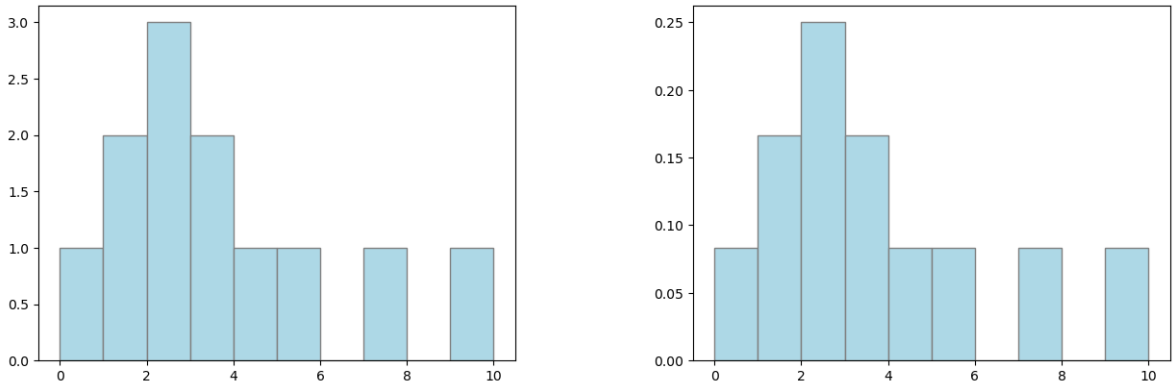

Figure 4 – Histogramme des effectifs à gauche (resp. des fréquences à droite).

- *Boîtes à Moustache.* Elle synthétise les informations des questions précédentes sur un même graphique.

```
# Boite à moustache
plt.boxplot(serie)
plt.show() # affichage
```

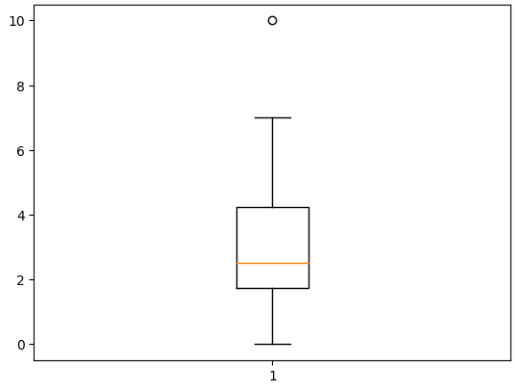

6. (a)

(b)

(c)

7.

8.

Exercice 6 – Les salariés d'une société sont en grève. Ils ont constaté que, dans chacune des cinq catégories de salaires de l'entreprise, les revenus avaient baissé au cours de cette année. Le responsable syndical se présente dans le bureau du directeur avec comme preuve de ses arguments le tableau ci-dessous.

	Année 2018		Année 2019	
	Effectifs	Revenus mensuels	Effectifs	Revenus mensuels
Catégorie 1	3	1000	2	900
Catégorie 2	4	1500	3	1400
Catégorie 3	6	2000	4	1900
Catégorie 4	4	2500	6	2400
Catégorie 5	3	3000	5	2900

Le directeur affirme qu'il dépense sans cesse plus pour les salaires et que son comptable lui a affirmé que le salaire moyen, le salaire médian et le salaire modal avaient tous les trois augmenté cette année. Qui faut-il croire ? Commenter la situation.

Solution.

Exercice 7 – Douze personnes sont inscrites à une formation. Au début de celle-ci, les stagiaires passent une épreuve $\mathcal{A}$ notée sur 20. À la fin de la formation, ils sont confrontés à une nouvelle épreuve $\mathcal{B}$ de niveau identique. Les résultats sur ces deux épreuves sont résumés dans le tableau suivant :

Épreuve $\mathcal{A}$	3	4	6	7	9	10	9	11	12	13	15	4
Épreuve $\mathcal{B}$	8	9	10	13	15	14	13	16	13	19	6	19

1. Représenter le nuage de points correspondant. Déterminer la droite de régression. Calculer le coefficient de détermination. Commenter.
2. Deux stagiaires semblent se distinguer des autres. Retirer-les de l'étude et déterminer la nouvelle droite de régression sur les 10 points restants. Calculer le carré du coefficient de corrélation, puis commenter.

Solution. 1.

2.

Exercice 8 – On appelle *distance quadratique* de la droite de régression de Y en X (d'équation $y = \hat{a}x + \hat{b}$) au nuage de points $\{(x_1, y_1), \ldots, (x_n, y_n)\}$ la quantité :

$$\delta = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\Big(y_i - (\hat{a}x_i + \hat{b}\Big)^2}.$$

Démontrer que

$$\delta = s_Y\sqrt{1 - r(X,Y)^2}, \qquad \text{où} \quad r(X,Y)^2 = \frac{\mathrm{Cov}(X,Y)^2}{s_X^2 s_Y^2}.$$

Interpréter ce résultat.

Solution. Puisque la droite de régression passe par le point $(\overline{x}, \overline{y})$, on a

$$\overline{y} = \hat{a}\overline{x} + \hat{b}.$$

Ainsi en écrivant $\hat{b} = \overline{y} - \hat{a}\overline{x}$, puis en substituant dans δ^2, nous obtenons

$$\begin{aligned}
\delta^2 &= \frac{1}{n}\sum_{i=1}^{n}\Big(y_i - \overline{y} - \hat{a}(x_i - \overline{x})\Big)^2 \\
&= \frac{1}{n}\sum_{i=1}^{n}\Big(y_i - \overline{y}\Big)^2 - \frac{2\hat{a}}{n}\sum_{i=1}^{n}\big(x_i - \overline{x}\big)\big(y_i - \overline{y}\big) + \frac{\hat{a}^2}{n}\sum_{i=1}^{n}\big(x_i - \overline{x}\big)^2 \\
&= s_Y^2 - 2\hat{a}\mathrm{Cov}(X,Y) + \hat{a}^2 s_X^2.
\end{aligned}$$

Or puisque $\hat{a} = \frac{\mathrm{Cov}(X,Y)}{s_X^2}$, nous en déduisons que

$$\begin{aligned}
\delta^2 &= s_Y^2 - 2\frac{\mathrm{Cov}(X,Y)^2}{s_X^2} + \frac{\mathrm{Cov}(X,Y)^2 s_X^2}{s_X^4} \\
&= s_Y^2 - \frac{\mathrm{Cov}(X,Y)^2}{s_X^2} \\
&= s_Y^2\Big(1 - \frac{\mathrm{Cov}(X,Y)^2}{s_X^2 s_Y^2}\Big) \\
&= s_Y^2\big(1 - r(X,Y)^2\big).
\end{aligned}$$

D'où l'égalité $\delta = s_Y\sqrt{1 - r(X,Y)^2}$.
La variable δ est l'estimateur des moindre carrées, c'est-à-dire la variance des résidus autour de la droite de régression des moindre carrés. Par définition, $\delta^2 \geq 0$, et donc $r(X,Y)^2 \leq 1$, *i.e.* $-1 \leq r(X,Y) \leq 1$. De plus, $r(X,Y) = \pm 1$ si, et seulement si, $\delta^2 = 0$. C'est exactement le cas lorsque tous les points $(x_1, y_1), \ldots, (x_n, y_n)$ appartiennent à la même droite. À l'inverse, si $r(X,Y) = 0$, alors la pente de la droite de régression linéaire est nulle et donc $\delta^2 = s_Y^2$ et il n'y a pas de corrélation entre X et Y.

La variable $r(X,Y)^2$ est appelée **coefficient de détermination**. Il s'agit de la proportion de variabilité de Y qui peut être expliquée par une relation linéaire $y = ax + b$.