Balade autour de

par

Léo Dort[1]

Résumé — Ces notes constituent une (très) courte introduction aux tests statistiques paramétriques. Nous définissons tout d'abord la notion de test statistique, ainsi que le risque associé à un tel test. Puis nous donnons la méthodologie pour construire un test, avant de terminer par l'étude détaillée d'un exemple.

Table des matières

1. Qu'est-ce qu'un test statistique ? 2
2. Que signifie « se tromper » et dans quelle mesure l'« accepter » ? 2
3. Seuil d'un test & p-valeur 3
4. Construction d'un test statistique 3
5. Un exemple de construction de test statistique paramétrique 4
   5.1. Contexte 4
   5.2. Construction du test 5
   5.3. Application numérique 7
   5.4. Déterminer la p-valeur 7

1. leo.dort@insa-lyon.fr

§1. Qu'est-ce qu'un test statistique ?

Le but d'un test statistique est de vérifier si une hypothèse est valide ou non. Par exemple, dans l'industrie pharmaceutique nous voulons déterminer si le médicament développé est efficace ou non contre la maladie étudiée. Une fois le problème posé et l'hypothèse qui nous intéresse formulée, nous voulons étudions sa vraisemblance. Pour cefaire, nous nous intéressons à la notion de test statistique.

Définition 1.1. Un **test statistique** est une procédure qui permet de décider si à partir des observations obtenues nous devons accepter ou rejeter l'hypothèse concernée.

Cependant, en raison de la variabilité des mesures (de l'aléatoire se cachant derrière les données obtenues), un tel test ne peut pas être catégorique : il faut donc accepter de se tromper dans la conclusion, **mais** en sachant avec quelle probabilité nous risquons de nous tromper.

§2. Que signifie « se tromper » et dans quelle mesure l'« accepter » ?

Un exemple pour illustrer cette notion d'erreur de conclusion. Le maire d'une ville décide d'étudier la concentration de plomb dans une vieille école. Il effectue plusieurs mesures et obtient un indicateur de $1\mu g.m^{-3}$ (par exemple la moyenne), sachant que la norme européenne (2006) à ne pas dépasser est de $0.9\mu g.m^{-3}$.

Doit-il suspendre la venue des enfants à dans cette école ?

L'hypothèse que veut tester le maire est "la norme est dépassée", mais il a deux façons de se tromper dans sa conclusion :

— s'il conclue que la norme est dépassée, alors qu'en réalité ce n'est pas le cas, mais que l'écart dans les observations est uniquement dû à l'aléatoire des mesures, alors l'école sera fermée sans justification ; et

— s'il conclue que la norme n'est pas dépassée, alors qu'en réalité c'est le cas, alors il y a un risque de santé publique pour les enfants et toutes les personnes travaillant dans cette école.

Nous notons généralement $(\mathcal{H}_0)$ l'**hypothèse nulle** c'est-à-dire l'hypothèse que nous souhaitons tester, et $(\mathcal{H}_1)$ l'**hypothèse alternative**.

> En fait, lorsque nous testons une hypothèse $(\mathcal{H}_0)$, nous testons en réalité si cette hypothèse est plus vraisemblable qu'une hypothèse alternative $(\mathcal{H}_1)$.

En général, les hypothèses $(\mathcal{H}_0)$ et $(\mathcal{H}_1)$ sont complémentaires. Au vu de l'exemple ci-dessus, nous distinguons deux types de risque :

(a) le **risque de rejeter** $(\mathcal{H}_0)$ **à tort** : il s'agit du *risque de 1ère espèce* ; et

(b) le **risque de ne pas rejeter** $(\mathcal{H}_0)$ **à tort** : il s'agit du *risque de 2ème espèce.*

Idéalement, nous voudrions minimiser ces deux risques simultanément dans notre procédure de test. Mais ceci n'est pas faisable et par convention, nous décidons de contrôler le risque de 1ère espèce.

§3. Seuil d'un test & p-valeur

Définition 3.1. Un test de **seuil** α est un test dont le risque de 1ère espèce vaut α. Autrement dit, *la probabilité de conclure* $(\mathcal{H}_0)$ *est faux lorsque* $(\mathcal{H}_0)$ *est vérifiée vaut* α.

Le choix des hypothèses se fait alors à partir de la formulation du risque qui nous intéresse. La personne qui réalise le test veut minimiser le risque de 1ère espèce. Dans l'exemple ci-dessus, le maire (que nous supposons honnête) veut minimiser le risque d'affirmer que la norme de concentration de plomb est respectée à tord, en raison du risque pour les enfants et le personnel de l'école. Son hypothèse $(\mathcal{H}_0)$ est donc « la norme est dépassé ». Un expert mandaté par un tiers souhaitant laisser l'école ouverte choisira au contraire comme hypothèse $(\mathcal{H}_0)$ « la norme est respectée ».

En fonction du seuil α fixé, la conclusion d'un test peut ne pas être la même. Par exemple, pour $\alpha \geqslant 1\%$, nous pourrions rejeter l'hypothèse $(\mathcal{H}_0)$, mais pour $\alpha \leqslant 0.5\%$ nous ne la rejeterions pas. Ceci signifie que si nous affirmons que $(\mathcal{H}_1)$ est valide, la probabilité de se tromper est comprise entre 0.5% et 1%. Nous pouvons montrer qu'il existe un *seuil critique* à partir duquel la conclusion du test change.

La notion mise en évidence ici est fondamentale : il s'agit de la **p-valeur** d'un test.

Définition 3.2. La **p-valeur** d'un test est le seuil critique α_c du risque tel que, lorsque nous réalisons le test avec un seuil α :

$$\begin{cases} \text{si } \alpha \leqslant \alpha_c, & \text{alors nous ne rejetons pas } (\mathcal{H}_0) \\ \text{si } \alpha > \alpha_c, & \text{alors nous rejetons } (\mathcal{H}_0). \end{cases}$$

> Si la p-valeur est faible, ça signifie donc que nous pouvons rejeter $(\mathcal{H}_0)$ avec un faible risque de se tromper.

En général, nous cherchons à obtenir une p-valeur petite, de sorte à pouvoir valider l'hypothèse $(\mathcal{H}_1)$ avec un faible risque de se tromper.

Souvent les logiciels ne donnent que la p*-valeur : elle résume à elle seule le résultat du test pour tous les seuils et donne une information supplémentaire qu'est le risque maximal que nous prenons en rejetant* $(\mathcal{H}_0)$.

§4. Construction d'un test statistique

Détaillons un peu plus précisément en quoi consiste un test statistique. Rappelons que nous souhaitons répondre à une problématique, et que nous avons donc une *prise de décision* et un *risque associé que nous voudrions contrôler.*

Comment, au vu des données, allons-nous procéder ?

Les étapes de construction d'un test sont les suivantes :

1. Formaliser le problème et la décision à prendre.
2. Expliciter le risque que nous cherchons à minimiser. En déduire les hypothèses $(\mathcal{H}_0)$ et $(\mathcal{H}_1)$.

3. Choisir le seuil du risque α en fonction de la gravité des conséquences : plus α est petit, plus le risque associé est petit.
   En général, nous prenons ce seuil α inférieur à 5%.
4. Construire une **règle de décision**, c'est-à-dire une procédure qui permette de dire si nous acceptons ou non $(\mathcal{H}_0)$ au vu des données $x_1, \dots, x_n$. Cette procédure consiste à trouver une **région critique**, que nous notons RC_α telle que :
   — si $\{x_1, \dots, x_n\} \in \mathrm{RC}_\alpha$, alors nous rejetons $(\mathcal{H}_0)$; et
   — si $\{x_1, \dots, x_n\} \notin \mathrm{RC}_\alpha$, alors nous ne rejetons pas $(\mathcal{H}_0)$.
5. Répondre à la question : les observations $\{x_1, \dots, x_n\}$ appartiennent-elles à RC_α ? Conclure quant au rejet ou au non-rejet de l'hypothèse $(\mathcal{H}_0)$.
6. Répondre au problème posé.

Une étape fondamentale de la construction d'un test reste la détermination de la région critique. Par définition, la région critique est une condition telle que si les observations la vérifie, alors nous rejetons $(\mathcal{H}_0)$.

Comment déterminer cette condition ?

Nous pouvons distinguer deux types de tests pour la construction de cette région critique.

(a) **Tests paramétriques.** Les données observées sont modélisées (nous supposons par exemple qu'elles sont issues d'une certaine loi de probabilité et que les observations sont indépendantes). L'hypothèse peut se formuler à l'aide d'un paramètre θ, que le modèle permet d'estimer. Nous n'avons pas accès à la vraie valeur de θ, mais nous prenons notre décision au vu de son estimation et de sa précision.
Exemples : la concentration de plomb dans un bâtiment sui une loi normale d'espérance θ et le test se formulera sur θ ; la réponse à un sondage est une loi de Bernoulli $\mathcal{B}\mathrm{er}(p)$ avec p le score du sondage : le candidat gagne si $p \geqslant 50\%$, etc.

(b) **Tests non-paramétriques.** Nous voulons tester une hypothèse indépendamment de toute modélisation préalable de nos données. Nous pourrions par exemple vouloir tester si les données suivent bien une loi normale ou une loi de Poisson, ou bien tester si deux variables sont corrélées, etc.

§5. Un exemple de construction de test statistique paramétrique

Dans cette partie, nous notons le variables aléatoires en lettres capitales. Les mêmes lettres minuscules sont réservées aux réalisations de ces variables aléatoires. Par exemple, si nous lançons deux dés nous pourrions considérer la variable aléatoire X calculant la somme de ces dés. La quantité $x = 7$ est réalisation de la variable aléatoire X si nous effectuons cette expérience et que nous obtenons 7 au lancer des dés.

5.1. Contexte. Un sondage est réalisé lors avant une élection sur $n = 500$ personnes. À l'issu du sondage, la candidat A reçoit le score de $\widehat{p}_n = 274/500 = 54.8\%$ des voies des personnes sondées. Nous aimerions savoir si le candidat A va gagner les élections.

5.2. Construction du test. Notons p le (vrai) score de A sur la population. Nous souhaitons effectuer le test suivant :

$$(\mathcal{H}_0) : p \leqslant 50\% \quad \text{contre} \quad (\mathcal{H}_1) : p > 50\%.$$

Les données $X_1, \dots, X_n$, qui représentent les réponses au sondage, sont des variables aléatoires indépendantes suivants une loi de Bernoulli $\mathcal{B}er(p)$ de paramètre p. Ce paramètre p est estimé par la proportion observée $\widehat{p}_n$.

Construisons la région critique RC_α de risque α pour le test

$$(\mathcal{H}_0) : p \leqslant p_0 \quad \text{contre} \quad (\mathcal{H}_1) : p > p_0.$$

Dans notre exemple, $p_0 = 50\%$ est la proportion de référence à laquelle nous souhaitons comparer p [2]. D'après la définition de a région critique et de du test ci-dessus, nous recherchons une région critique sous la forme

$$RC_\alpha = \left\{\widehat{p}_n > p_0 + c_\alpha\right\}.$$

La constante c_α que nous déterminons ci-dessous quantifie le fait que $\widehat{p}_n$ doit être significativement plus grand que p_0 pour que nous acceptions $(\mathcal{H}_1)$.
Par définition de région critique, nous avons que

$$\alpha = \mathbb{P}\Big(RC_\alpha \text{ sous } (\mathcal{H}_0)\Big),$$

c'est-à-dire

$$\alpha = \mathbb{P}\Big(\widehat{P}_n > p_0 + c_\alpha\Big). \qquad (\text{☁})$$

Il est possible de déterminer la constante c_α en déterminant la loi de $\widehat{p}_n$ qui est la moyenne empirique des réponses, c'est-à-dire une moyenne de variables de Bernoulli indépendantes et identiquement distribuées

$$\widehat{p}_n = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

Mais afin de faciliter les calculs réécrivons tout d'abord la région critique sous la forme :

$$RC_\alpha = \left\{\frac{\widehat{p}_n - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} > \frac{c_\alpha}{\sqrt{\frac{p_0(1-p_0)}{n}}}\right\}.$$

Puisque le nombre d'observations est suffisamment grand, le théorème de Moivre-Laplace, énoncé ci-dessous, assure que nous pouvons approcher la quantité

$$U_n = \frac{\widehat{P}_n - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

par une loi normale centrée réduite $\mathcal{N}(0,1)$.

Théorème 5.1 (Théorème de Moivre-Laplace). *Si $X_1, X_2, X_3, \dots$ est une suite de variables aléatoires indépendantes de Bernoulli $\mathcal{B}er(p)$ de paramètre p, alors en notant $\widehat{P}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$*

2. Si dans un scrutin, il faut réunir 70% des voix pour être élu, alors nous aurions choisi $p_0 = 70\%$.

nous avons

$$\frac{\widehat{P}_n - p}{\sqrt{\frac{p(1-p)}{n}}} \xrightarrow[n\to+\infty]{\text{loi}} \mathcal{N}(0,1),$$

où $\mathcal{N}(0,1)$ *désigne une variable aléatoire normale centrée réduite.*

Par conséquent, l'égalité ( ) se réécrit maintenant en fonction de U_n comme :

$$\alpha = \mathbb{P}\left(U_n > \frac{c_\alpha}{\sqrt{\frac{p_0(1-p_0)}{n}}}\right),$$

et si nous posons

$$u_\alpha = \frac{c_\alpha}{\sqrt{\frac{p_0(1-p_0)}{n}}},$$

(qui est une quantité qui ne dépend que des paramètres connus α, p_0 et n), nous obtenons

$$\alpha = \mathbb{P}(U_n > u_\alpha).$$

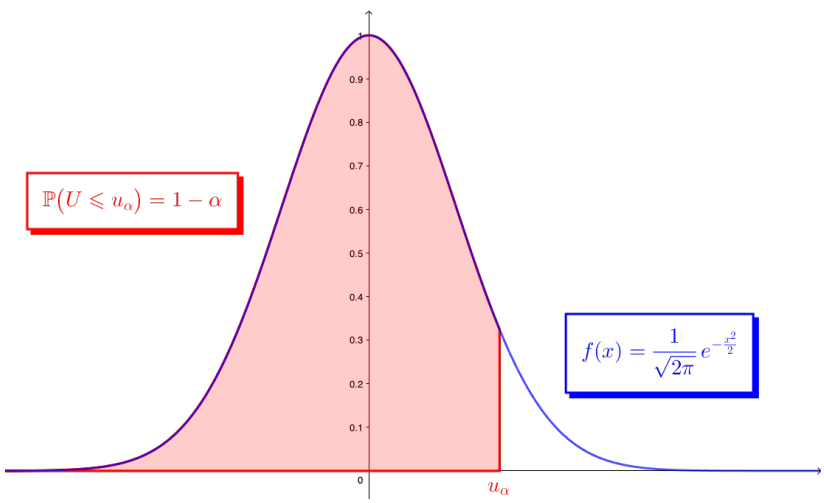

Figure 1 – Densité de la loi normale centrée réduite $\mathcal{N}(0,1)$ et le quantile u_α d'ordre $1-\alpha$ associé.

L'avantage de cette transformation est que nous connaissons très bien la loi normale, et il nous est très facile de déterminer la quantité u_α qui correspond au quantile d'ordre $1-\alpha$. Voir la figure ci-dessous. Ceci nous permet alors de déterminer la constante c_α précédente :

$$c_\alpha = u_\alpha \sqrt{\frac{p_0(1-p_0)}{n}},$$

et ainsi déterminer la région critique associée au test (écrite en fonction de u_n, puis en fonction de $\widehat{p}_n$ qui sont les réalisations respectives de U_n et $\widehat{P}_n$) :

$$\begin{aligned} \mathrm{RC}_\alpha &= \{u_n > u_\alpha\} \\ &= \left\{\widehat{p}_n > p_0 + u_\alpha \sqrt{\frac{p_0(1-p_0)}{n}}\right\}. \end{aligned}$$

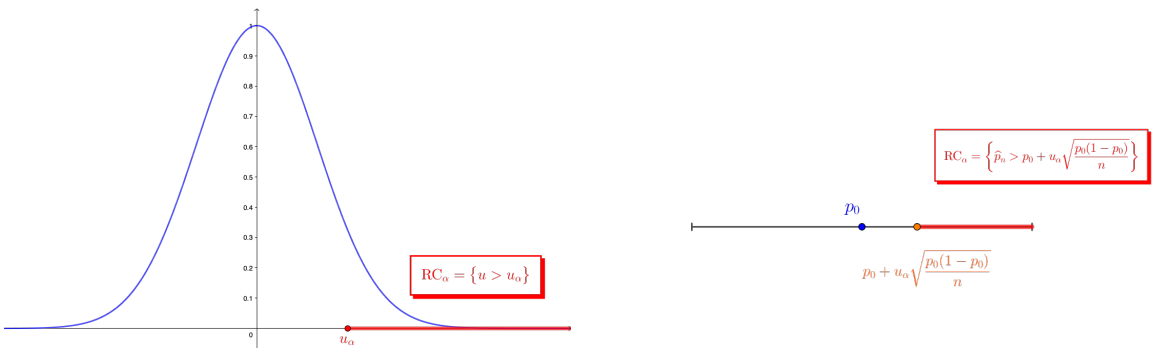

Figure 2 – Région critique de risque α associée au test écrite en termes de loi normale et par rapport au paramètre de proportion originel.

5.3. Application numérique. Passons maintenant à l'application numérique. Fixons le seuil de risque $\alpha = 0.05$. Dans ce cas, il est connu que le quantile d'ordre $1 - 0.05$ est $u_{0.05} = 1.96$. La proportion de référence $p_0 = 0.5$. Ainsi,

$$p_0 + u_\alpha\sqrt{\frac{p_0(1-p_0)}{n}} = 0.5 + 1.96\sqrt{\frac{0.5(1-0.5)}{500}} = 0.5438.$$

Ainsi la région critique de risque α associée au test est

$$\mathrm{RC}_{0.05} = \{\widehat{p}_n > 0.5438\}.$$

Puisque $\widehat{p}_n = 0.548 \in \mathrm{RC}_{0.05}$, nous en déduisons qu'avec un seuil de risque de 5% nous rejetons $(\mathcal{H}_0)$. Nous pouvons affirmer avec un risque de 5% d'erreur que le candidat A va gagner les élections.

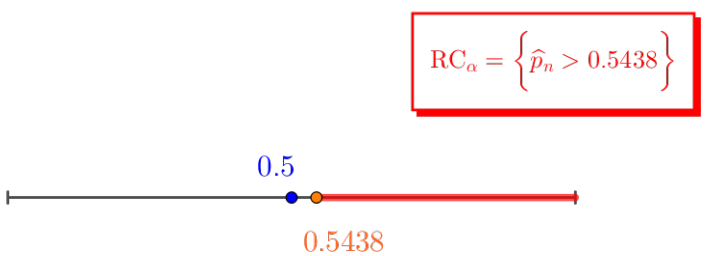

Figure 3 – Région critique de risque α associée au test.

5.4. Déterminer la p-valeur. Par définition, la p-valeur représente le seuil de risque critique à partir duquel la conclusion du test change. Celle-ci est atteinte lorsque

$$u_{\alpha_c} = \frac{\widehat{p}_n - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} = 2.147.$$

Soit $\Phi : \mathbb{R} \to [0,1]$ la fonction de répartition de la loi normale centrée réduite $\mathcal{N}(0,1)$, c'est-à-dire la fonction définie pour tout $x \in \mathbb{R}$ par

$$\Phi(x) = \mathbb{P}\big(U \leqslant x\big),$$

où $U \sim \mathcal{N}(0,1)$.
Par définition de u_α, si nous avons alors

$$\alpha_c = \mathbb{P}\big(U > u_{\alpha_c}\big) = 1 - \mathbb{P}\big(U \leqslant u_{\alpha_c}\big) = 1 - \Phi(u_{\alpha_c}).$$

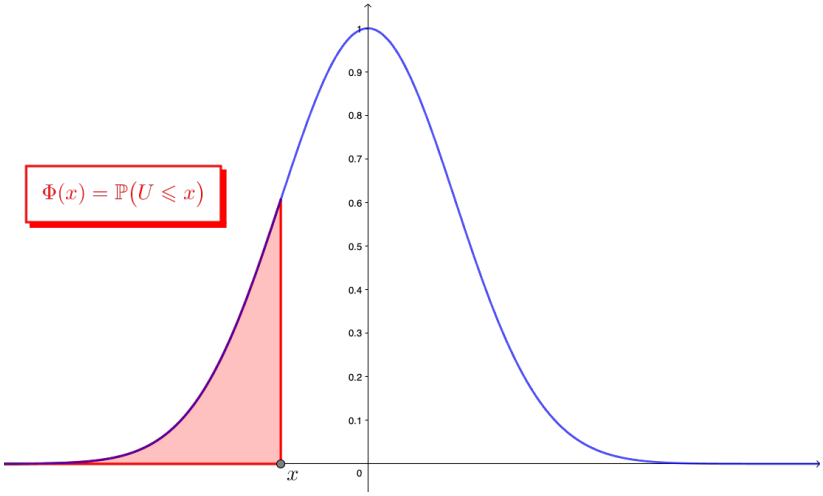

Figure 4 – Fonction de répartition de la loi normale $\mathcal{N}(0,1)$.

Dans notre cas, grâce à une table des valeurs ou par la calculatrice, nous obtenons

$$\alpha_c = 1 - \Phi(2.147) = 1 - 0.9842 = 1.6\%.$$

La p-valeur de ce test est donc 1.6%. Cela signifie donc que si nous acceptons de nous tromper avec une probabilité supérieure à 1.6%, nous pouvons affirmer que le candidat A va gagner les élections.

Remarque. Notons que cette conclusion peut se faire sous réserve que l'échantillon soit représentatif de la population, qu'aucun individu ne change d'avis, ni ne soit indécis, etc.